

ANALYSE DES DÉTERMINANTS DE LA SATISFACTION GLOBALE EN MAISON DE RETRAITE

Jeu de données : Retraite.xlsx — 300 résidents | 16 variables

Thème	Satisfaction des résidents en maison de retraite
Outils	Python · R · Pandas · Matplotlib · scikit-learn · ggplot2
Dépôt	github.com/mhayette/retraite-satisfaction
Date	25/06/2026

1. Contexte et Objectifs

Ce projet analyse les **déterminants de la satisfaction globale** des résidents en maison de retraite à partir d'un jeu de données de 300 résidents et 16 variables. L'objectif est d'identifier les leviers d'action prioritaires pour améliorer la qualité de vie des résidents et d'appuyer les recommandations par une modélisation statistique rigoureuse.

Objectif	Approche
Identifier les facteurs influençant la satisfaction	Corrélations, régression multivariée
Mesurer la performance des services	KPIs, bar charts, classement
Comparer la satisfaction par profil de résident	ANOVA, test de Tukey
Prédire la satisfaction selon des scénarios	Modèle linéaire, Random Forest

2. Présentation des Données

Le jeu de données **Retraite.xlsx** comprend **300 résidents** et **16 variables** couvrant le profil sociodémographique, les évaluations de services et la satisfaction globale.

Variable	Type	Description
Formule	Catégorielle	Type de formule souscrite
Public	Catégorielle	Degré d'autonomie (Valide, Semi-valide, Dépendant)
Activite	Catégorielle	Participation aux activités
Accueil ... Services_Annexes	Numérique (1–5)	Notes des 9 services évalués
Satisfaction	Numérique (1–10)	Variable cible — satisfaction globale
PRIX_PENSION	Numérique	Prix mensuel de la pension
Sexe / CSP	Catégorielle	Profil sociodémographique

■ Valeurs manquantes détectées sur Reconfort, Confort_Chambre et Services_Annexes → imputées par la **médiane** (robuste aux valeurs extrêmes).

3. Statistiques Descriptives

3.1 Satisfaction globale

La satisfaction est notée sur 10. La médiane est de **5/10**, révélant des avis partagés parmi les résidents. La distribution est relativement étalée (std $\approx$ 2.5).

3.2 Services (sur 5)

Les 9 services sont notés entre 1 et 5. Les moyennes se situent globalement entre 2 et 3, suggérant une satisfaction modérée. L'Hygiène et la Restauration ressortent comme les services les plus critiqués.

3.3 Prix de la pension

Le prix varie fortement selon la formule choisie (médiane $\approx$ 489 unités monétaires). Cette forte variabilité justifiait d'analyser son lien avec la satisfaction.

Indicateur	Valeur
Nombre de résidents	300
Satisfaction moyenne	$\approx$ 5.0 / 10
Médiane satisfaction	5 / 10
Prix médian pension	$\approx$ 489
Variables avec NA	3 (Reconfort, Confort_Chambre, Services_Annexes)
Corrélation Prix/Satisfaction	$r = 0.095$ (quasi nulle)

4. Modélisation — Régression Linéaire

4.1 Régression univariée — Le Prix

La régression univariée entre le prix et la satisfaction confirme l'absence de relation significative : $R^2 = 0.9\%$ et $p\text{-value} = 0.10 > 0.05$. Payer plus cher ne garantit pas une meilleure satisfaction.

4.2 Régression multivariée — Le modèle final

Après sélection des variables significatives, le modèle retenu est :

Satisfaction ~ Soins_Qualite + Competence_Personnel + Reconfort + Hygiene

Variable	Coefficient	Interprétation
Hygiene	0.43	Levier n°1 — chaque +1 pt → +0.43 pt de satisfaction
Soins_Qualite	0.36	2ème facteur le plus impactant
Reconfort	0.36	L'humain pèse autant que les soins techniques
Competence_Personnel	0.26	Important mais légèrement en retrait
R² global	15.6%	Ces 4 variables expliquent ~16% de la satisfaction
p-value globale	3.16e-10	Modèle hautement significatif

5. Analyse par Profil — ANOVA

L'ANOVA compare la satisfaction moyenne entre les trois types de résidents (Valide, Semi-valide, Dépendant). La p-value globale de **0.0036** < **0.05** conduit au rejet de H_0 : la satisfaction diffère significativement selon le degré d'autonomie.

Test de Tukey — Comparaisons par paires

Comparaison	Différence	p ajustée	Conclusion
Valides vs Semi-valides	-0.74 pt	0.0045	■ Significatif
Valides vs Dépendants	-0.58 pt	0.0648	■ Tendance (non sig. à 5%)
Semi-valides vs Dépendants	0.16 pt	0.8250	■ Aucune différence

→ Les résidents **Valides** sont significativement moins satisfaits que les Semi-valides. Hypothèse : les résidents valides sont plus exigeants sur des critères non encore explorés (animations, services annexes).

6. Tests de Validité du Modèle

Test	Résultat	Verdict
Shapiro-Wilk (normalité)	$p = 0.116 > 0.05$	■ Résidus normaux
VIF (multicolinéarité)	$VIF \approx 1.1$ pour toutes les variables	■ Pas de multicolinéarité
Breusch-Pagan (homoscédasticité)	$p = 0.010 < 0.05$	■ Légère hétéroscédasticité

Le modèle est globalement robuste. La légère hétéroscédasticité signifie que les prédictions sont moins précises pour les notes extrêmes (très basses ou très hautes).

7. Prédictions par Scénario

Le modèle final permet de simuler la satisfaction attendue selon le niveau de qualité des services :

Scénario	Services	Satisfaction prédite	IC 95%
Profil Moyen	3/5 partout	5.90 / 10	[5.46 – 6.34]
Profil Excellent	5/5 partout	8.71 / 10	[7.49 – 9.93]
Gain potentiel	3/5 → 5/5	+2.81 points	—

8. Conclusion et Recommandations

Cette analyse démontre que la satisfaction en maison de retraite repose sur **quatre piliers essentiels** : l'Hygiène, la Qualité des Soins, le Réconfort humain et la Compétence du personnel. Le prix de la pension, contrairement aux idées reçues, n'a aucun impact mesurable sur la satisfaction des résidents ($r = 0.095$).

Recommandations prioritaires :

- Prioriser l'**Hygiène** (levier n°1) : chaque point gagné sur ce critère génère +0.43 pt de satisfaction globale.
- Investir dans la **qualité des soins et le réconfort** : ces deux dimensions ont un impact quasi équivalent.
- Adapter l'offre aux **résidents Valides** : ce groupe est significativement moins satisfait (ANOVA $p < 0.01$).
- Ne pas augmenter les prix dans l'espoir d'améliorer la satisfaction perçue — l'effet est nul.
- Développer les activités et services annexes pour répondre aux attentes spécifiques des résidents autonomes.

Limites :

- Le R^2 de 15.6% indique que d'autres facteurs non mesurés influencent la satisfaction.
- Légère hétéroscédasticité : les prédictions sont moins précises sur les notes extrêmes.
- L'étude est transversale — un suivi longitudinal permettrait d'analyser l'évolution de la satisfaction.